

RAPPORT TECHNIQUE

Classification Multi-classe de Radiographies Pulmonaires pour la
Détection de la COVID-19

Utilisation de l'Architecture Xception avec Transfer Learning

Keita Hadiatou & Rouchdi Asmaa

haadikeita4@gmail.com - asmaarouchdi72@gmail.com

Novembre 2025

Intelligence Artificielle - Vision par Ordinateur

1. Objectif et rappel du problème

Résumé du projet :

Ce projet vise à développer un système intelligent de classification automatique de radiographies pulmonaires pour aider au diagnostic de la COVID-19. Le système utilise des techniques avancées de Deep Learning, notamment le Transfer Learning avec l'architecture Xception, pour distinguer trois types de cas cliniques à partir d'images radiographiques.

Secteur d'application :

Secteur : Santé - Diagnostic médical - Imagerie médicale (Radiologie)

Le projet s'inscrit dans le contexte de la crise sanitaire mondiale de la COVID-19, où la capacité de diagnostic rapide et précis est cruciale pour le contrôle de l'infection et la gestion des ressources hospitalières.

Problème métier :

La COVID-19 présente des manifestations radiologiques souvent similaires à d'autres pneumonies virales. Les radiologues font face à plusieurs défis : similarité des symptômes radiologiques, charge de travail élevée, besoin de rapidité pour le triage, et variabilité inter-observateur dans l'interprétation.

Tâche d'apprentissage supervisée :

Type : Classification multi-classe d'images (3 classes)

Entrée : Radiographie pulmonaire (299×299 pixels)

Sortie : Prédiction parmi 3 classes : COVID-19, Normal, Viral Pneumonia

KPIs métiers :

KPI	Cible	Justification
Recall COVID-19	> 90%	Minimiser faux négatifs (santé publique)
Precision globale	> 90%	Éviter fausses alertes
F1-Score	> 90%	Équilibre précision/rappel
AUC-ROC	> 0.95	Capacité de discrimination

Le **Recall COVID-19** est la métrique la plus critique car un faux négatif (patient COVID non détecté) représente un risque majeur de contamination et de retard de traitement.

2. Données utilisées

Source du dataset :

Dataset : COVID-19 Radiography Database

Source : Kaggle

(<https://www.kaggle.com/datasets/tawsifurrahman/covid19-radiography-database>)

Licence : Creative Commons Attribution 4.0 International (CC BY 4.0)

Taille et structure :

Le dataset contient environ **18,000 images** de radiographies pulmonaires.

Classe	Nombre d'images	Pourcentage
COVID-19	~3,600	~20%
Normal	~10,200	~56%
Viral Pneumonia	~4,500	~24%
Total	~18,300	100%

Prétraitements effectués :

1. Prétraitements de base :

- Redimensionnement : 299×299 pixels (format Xception)
- Normalisation : Application de preprocess_input Xception
- Encodage : One-Hot Encoding des labels (dimension 3)

2. Augmentation de données (train uniquement) :

- Rotation : $\pm 15^\circ$
- Translation horizontale/verticale : 10%
- Zoom : $\pm 10\%$
- Shear (cisaillement) : 10%
- Flip horizontal : Oui
- Fill mode : Nearest

3. Gestion du déséquilibre :

Utilisation de **class weights** inversement proportionnels aux fréquences des classes pour donner plus d'importance aux classes minoritaires (COVID-19 et Viral Pneumonia) pendant l'entraînement.

Répartition train/validation/test :

Ensemble	Pourcentage	Images (approx.)	Usage
Train	70%	12,810	Entraînement du modèle
Validation	15%	2,745	Ajustement hyperparamètres
Test	15%	2,745	Évaluation finale

Le split a été effectué en préservant les proportions des classes (stratification) pour garantir une évaluation représentative. Une graine aléatoire fixe (seed=42) a été utilisée pour assurer la reproductibilité.

3. Modèle développé

Architecture du réseau :

Nous avons choisi l'architecture **Xception** (Extreme Inception) développée par François Chollet en 2017 pour plusieurs raisons :

- Convolutions séparables en profondeur plus efficaces
- Performance supérieure en imagerie médicale
- Efficacité paramétrique (meilleur ratio performance/paramètres)
- Pré-entraîné sur ImageNet (1.4M images, 1000 classes)

Structure du modèle complet :

1. **Couche d'entrée** : 299×299×3 (images RGB)
2. **Xception Base** : 22.9M paramètres pré-entraînés sur ImageNet
3. **GlobalAveragePooling2D** : Réduit chaque carte de caractéristiques
4. **Couches personnalisées** :
 - Dense(512) + ReLU + BatchNorm + Dropout(0.5)
 - Dense(256) + ReLU + BatchNorm + Dropout(0.3)
5. **Sortie** : Dense(3, softmax) - Distribution de probabilités

Paramètres principaux :

Paramètre	Phase 1 (Base gelée)	Phase 2 (Fine-tuning)
Epochs	15	10
Batch size	32	32
Learning rate	0.001	1×10 ⁻⁴
Optimizer	Adam	Adam
Loss	Categorical Crossentropy	Categorical Crossentropy
Couches dégelées	0 (base gelée)	30 dernières couches

Callbacks : EarlyStopping (patience=5), ReduceLROnPlateau (factor=0.5, patience=3), ModelCheckpoint (sauvegarde meilleur modèle)

Justification du choix :

Xception offre le meilleur compromis performance/efficacité pour notre cas d'usage. Les convolutions séparables permettent une meilleure extraction des caractéristiques tout en réduisant le nombre de paramètres. Le Transfer Learning depuis ImageNet fournit des caractéristiques bas-niveau transférables aux images médicales. La stratégie de fine-tuning en 2 phases évite le catastrophic forgetting (oubli catastrophique).

4. Entraînement et évaluation

Métriques de performance :

Métrique	Valeur
Accuracy	96.48%
Precision (weighted)	96.57%
Recall (weighted)	96.48%
F1-Score (weighted)	96.52%
Loss	0.0981

Métriques par classe :

Classe	Precision	Recall	F1-Score	Support	AUC-ROC
COVID-19	95.90%	94.84%	95.37%	543	0.9954
Normal	97.39%	97.45%	97.42%	1,529	0.9929
Viral Pneumonia	91.30%	93.56%	92.42%	202	0.9982
Weighted Avg	96.49%	96.48%	96.48%	2,274	0.9970

Un AUC-ROC proche de 1.0 indique une discrimination quasi-parfaite entre les classes. Nos résultats (>0.99) sont exceptionnels.

Analyse des courbes d'entraînement :

Phase 1 (Epochs 1-15) : Convergence rapide, train accuracy de 71% à 90%, validation accuracy atteint 94.02%, pas d'overfitting significatif.

Phase 2 (Epochs 16-25) : Amélioration progressive avec fine-tuning, validation accuracy atteint 96.83% (epoch 23), gain de +2.81 points, courbes train/val restent proches (bonne généralisation).

Matrice de confusion :

Vérité ↓ / Prédictions →	COVID	Normal	Viral Pneu.	Total
COVID-19	515	27	1	543
Normal	22	1,490	17	1,529
Viral Pneumonia	0	13	189	202

Total	537	1,530	207	2,274
-------	-----	-------	-----	-------

Analyse des erreurs principales :

Sur 543 cas COVID-19, le modèle a fait **28 erreurs** (5.16% de faux négatifs) :

- 27 COVID → Normal : Cas avec opacités légères, images de faible qualité, stades très précoces
- 1 COVID → Viral Pneumonia : Symptômes radiologiques très similaires (acceptable cliniquement)

Sur 1,529 cas normaux, **39 erreurs** (2.55%) - Excellent taux

Sur 202 cas de pneumonie virale, **13 erreurs** (6.44%) - Acceptable

Pistes d'amélioration :

- **Data augmentation avancée** : Mixup/CutMix, AutoAugment, elastic deformation
- **Fine-tuning plus agressif** : Dégeler plus de couches, learning rate cyclique
- **Ensemble Learning** : Combiner Xception + ResNet152 + EfficientNetB7
- **Techniques avancées** : Attention mechanisms, Grad-CAM, Test-Time Augmentation
- **Dataset amélioré** : Plus d'images COVID-19, meilleure qualité, validation par experts
- **Validation clinique** : Tests prospectifs, évaluation par radiologues, comparaison avec PCR

5. Conclusion

Bilan du projet :

Ce projet a permis de développer avec succès un système de classification automatique de radiographies pulmonaires pour la détection de la COVID-19 utilisant le Transfer Learning avec l'architecture Xception. Tous les KPIs métiers ont été largement dépassés, démontrant l'efficacité de notre approche.

Objectif	Cible	Atteint	Statut
Accuracy globale	> 90%	96.48%	✓
Recall COVID-19	> 90%	94.84%	✓
F1-Score	> 90%	96.52%	✓
AUC-ROC	> 0.95	0.9970	✓

Limites et biais identifiés :

Limites techniques :

- Dataset déséquilibré : Classe COVID-19 sous-représentée (20%)
- Qualité variable : Sources multiples avec résolutions/contrastes différents
- Validation limitée : Testé uniquement sur dataset public Kaggle

Biais potentiels :

- Biais d'équipement : Variations entre appareils de radiographie
- Biais de population : Origines géographiques non uniformes
- Biais de confirmation : Labels basés sur PCR (possible circularité)

Limitations cliniques :

- Ne remplace pas le diagnostic médical (outil d'aide uniquement)
- Faux négatifs COVID (5.16%) : Risque de contamination
- Cas atypiques : Performance dégradée
- Aspect temporel non pris en compte

Perspectives d'évolution :

Court terme (3-6 mois) :

- Amélioration du dataset (plus d'images COVID-19, standardisation qualité)
- Optimisation du modèle (hyperparameter tuning, test autres architectures)
- Explainability (implémentation Grad-CAM, validation par radiologues)

Moyen terme (6-12 mois) :

- Validation clinique (étude prospective, comparaison avec experts)

- Déploiement pilote (API REST, interface utilisateur, tests en urgence)
- Multi-modalité (métadonnées cliniques, fusion avec CT scan)

Long terme (12+ mois) :

- Système de production (certification médicale CE/FDA, déploiement multi-hospitalier)
- Extension des capacités (autres pathologies, estimation sévérité, analyse longitudinale)
- Recherche avancée (Federated Learning, Zero-shot learning, rapports automatiques)

Avec plus de temps ou de ressources :

- **Plus de temps** : Exploration de 5-10 architectures, hyperparameter optimization exhaustive, validation sur plusieurs datasets publics
- **Plus de ressources computationnelles** : Entraînement 50-100 epochs, batch sizes plus larges, ensemble de 5-10 modèles, Neural Architecture Search
- **Plus de ressources données** : Collecte 50,000+ images, équilibrage parfait, annotation par 3-5 radiologues, données multi-modales
- **Collaboration médicale** : Validation prospective, feedback utilisateurs, certification médicale, publication scientifique

Conclusion finale :

Ce projet démontre le potentiel du Deep Learning pour assister le diagnostic médical de la COVID-19 à partir de radiographies pulmonaires. Avec une accuracy de 96.48% et un recall COVID-19 de 94.84%, notre modèle basé sur Xception atteint des performances prometteuses pour un usage clinique après validation.

L'objectif pédagogique est pleinement atteint : nous avons développé, entraîné et évalué un modèle de Deep Learning performant, documenté rigoureusement notre démarche, et identifié les axes d'amélioration future.

AVERTISSEMENT FINAL

Ce modèle est un outil d'aide à la décision développé dans un cadre éducatif. Il ne doit en aucun cas remplacer l'expertise médicale d'un professionnel de santé qualifié. Toute décision diagnostique ou thérapeutique doit être prise par un médecin. Une validation clinique approfondie, incluant des études prospectives et une certification réglementaire, serait indispensable avant tout déploiement en environnement hospitalier réel.

Novembre 2025

Keita Hadiatou & Rouchdi Asmaa
Intelligence Artificielle - Vision par Ordinateur